

Chebyshev DeepONet: 谱方法边界约束神经网络

用于 Kerr 时空 Teukolsky 方程齐次径向解的高精度 PINN 替代方案

2026 年 5 月 10 日

摘要

针对 Teukolsky 方程齐次径向函数的 PINN 求解，我们提出 Chebyshev DeepONet——一种将 Chebyshev 谱方法与 DeepONet 算子学习框架相结合的神经网络架构。该架构通过解析构造精确满足视界边界条件 $f(y=1)=1$ ，以 Chebyshev 多项式作为空间基底实现谱精度，并通过精确导数递推消除自动微分的数值噪声。在相同参数规模（200K）下，训练速度比现有 PINN_MLP 快 2.1 倍，且不需要 Fourier 特征、FiLM 调制或残差连接等复杂设计。

1 问题背景

1.1 Teukolsky 方程与 Atlas-PINN

考虑 Kerr 时空中的 Teukolsky 主方程，其齐次径向部分可写为

$$\Delta^{-s} \frac{d}{dr} \left(\Delta^{s+1} \frac{dR}{dr} \right) + V(r)R = 0, \quad (1)$$

其中 $\Delta = r^2 - 2Mr + a^2$ ， $s = -2$ 为引力微扰自旋权重， $V(r)$ 依赖于角向本征值 λ 和频率 ω 。

Atlas-PINN 策略将参数空间 (a, ω) 划分为若干重叠的 patch，在每个 patch 上训练一个局部神经网络来近似视界入射解 $R_{\text{in}}(r; a, \omega)$ 。当前模型（PINN_MLP）采用双支路 MLP + Fourier 特征 + FiLM 条件调制 + Taylor 展开输出结构，在最优配置下达到 $\sim 1\%$ 的相对精度。

1.2 当前方法的局限

PINN_MLP 存在几个结构性问题：

- 无边界条件约束：**视界处 $f(1)=1$ 的正则条件完全依赖 PDE 残差和积分一致性损失来软约束，增加了优化难度。
- 自动微分开销：** f_y 和 f_{yy} 通过 autograd 逐样本循环计算，batch size=8 时训练步耗时 1.3s。
- MLP 的谱偏差：**即使加入 Fourier 特征，MLP 仍偏向低频函数，对近视界区域的快速变化捕捉效率低。

2 Chebyshev DeepONet 架构设计

2.1 整体思路

将深度算子网络（DeepONet）框架与 Chebyshev 谱方法结合：

- **Branch net**（参数网络）：将 (a, ω) 映射为 Chebyshev 系数 $\{c_n(a, \omega)\}_{n=0}^{N-1}$ 。
- **Trunk**（空间基函数）： y 方向使用 Chebyshev 多项式 $\{T_n(y)\}_{n=0}^{N-1}$ 作为固定基底。
- **输出**： $h(y; a, \omega) = \sum_{n=0}^{N-1} c_n(a, \omega) T_n(y)$ ，通过 Clenshaw 递推求值。

2.2 硬边界约束

核心设计：将视界边界条件 $f(1) = 1$ 解析地植入网络输出中：

$$\boxed{f(y; a, \omega) = 1 + (1 - y) \cdot h(y; a, \omega)} \quad (2)$$

由构造保证：

- $f(1) = 1 + 0 \cdot h(1) = 1$ —— 精确成立，无需神经网络学习。
- $f'(1) = -h(1)$ —— 由网络自由学习，受 PDE 残差约束。

这种”硬编码边界 + 自由内部”的设计比完全软约束有更好的优化特性：损失景观中消除了边界处的平凡误差源，优化器可以将容量集中于内部区域。

2.3 Taylor 展开结构（参数依赖）

继承 PINN_MLP 的 Taylor 展开策略，将 $h(y)$ 分解为 patch 中心解与参数修正：

$$h(y; a, \omega) = h_{\text{base}}(y) + \alpha h_a(y) + \xi h_\omega(y) + (\alpha^2 + \xi^2) h_{\text{nl}}(y), \quad (3)$$

其中 $\alpha = (u - u_c)/h_u$ 、 $\xi = (v - v_c)/h_v$ 是 atlas patch 的局部归一化坐标。每个 $h_*(y)$ 对应一组独立的 Chebyshev 系数，由参数网络分别输出。

2.4 参数网络（Branch）

参数特征向量（14 维）：

$$\mathbf{p} = [\alpha, \xi, \alpha^2, \xi^2, \alpha\xi, r_+, \sqrt{1 - a^2/M^2}, \Omega_H, k, \log_{10} \omega, \sin(\pi\alpha), \cos(\pi\alpha), \sin(\pi\xi), \cos(\pi\xi)]. \quad (4)$$

通过 4 层全连接编码器处理后，4 个独立输出头各产生 N 个复系数：

$$\{c_n^{\text{base}}\}_{n=0}^{N-1}, \{c_n^a\}_{n=0}^{N-1}, \{c_n^\omega\}_{n=0}^{N-1}, \{c_n^{\text{nl}}\}_{n=0}^{N-1} \leftarrow \text{MLP}(\mathbf{p}). \quad (5)$$

2.5 导数计算：无自动微分的谱精度

这是 Chebyshev 表示的关键优势。对 $h(y) = \sum_n c_n T_n(y)$ ：

$$h'(y) = \sum_n c'_n T_n(y), \quad c'_n \text{ 由 Chebyshev 系数递推得到}, \quad (6)$$

$$h''(y) = \sum_n c''_n T_n(y), \quad c''_n \text{ 同理}. \quad (7)$$

Chebyshev 导数系数的递推公式 (Canuto et al. 2006)：

$$c'_N = c'_{N-1} = 0, \quad c'_{n-1} = c'_{n+1} + 2nc_n, \quad c'_0 = c'_2/2 + c_1. \quad (8)$$

结合硬边界约束，完整函数及导数为：

$$f(y) = 1 + (1 - y)h(y), \quad (9)$$

$$f_y(y) = -h(y) + (1 - y)h_y(y), \quad (10)$$

$$f_{yy}(y) = -2h_y(y) + (1 - y)h_{yy}(y). \quad (11)$$

整个过程 无需对 y 做自动微分，消除了 PINN_MLP 中最耗时的逐样本梯度计算。

2.6 模型规格与参数量

表 1: ChebDeepONet 默认配置

参数	值
Chebyshev 阶数 N	48
编码器隐藏层	[128, 256, 256, 128]
参数嵌入维度	128
激活函数	SiLU
输出头数	4 (base, a , ω , nl)
总参数量	199,680
训练精度	float64

3 与 PINN_MLP 的对比

ChebDeepONet 用更简单的结构（无 FiLM、无 Fourier、无残差）实现了更快的训练和更干净的优化：

- 硬边界约束消除了视界处的损失噪声。
- 谱精度意味着更少的配置点即可达到相同精度。
- 精确导数避免了 autograd 的数值误差和计算开销。

表 2: 两种架构对比 (batch=8, $N_y=128$, float64, CUDA)

	PINN_MLP	ChebDeepONet
参数量	240K	200K
每步耗时 (含导数)	1.34s	0.64s
速度提升	—	$\times 2.1$
y 特征提取	Multi-scale Fourier	无 (Chebyshev 自带)
参数调制	FiLM	无 (Taylor 头分离)
残差连接	有	无
$f(1) = 1$ 约束	软约束 (PDE loss)	硬约束 (解析保证)
y 导数计算	autograd	Chebyshev 递推 (解析)
y 方向精度	MLP 插值	谱精度

4 实现细节

4.1 Clenshaw 求值

Chebyshev 级数通过 Clenshaw 递推在 $O(N)$ 内求值 (比直接求和数值更稳定):

```

1:  $b_N \leftarrow 0, b_{N+1} \leftarrow 0$ 
2: for  $k = N - 1, N - 2, \dots, 1$  do
3:    $b_k \leftarrow 2y \cdot b_{k+1} - b_{k+2} + c_k$ 
4: end for
5:  $\text{result} \leftarrow y \cdot b_1 - b_2 + c_0$ 

```

4.2 与现有训练框架的集成

ChebDeepONet 的 `forward(a, omega, y, u, v)` 接口与 PINN_MLP 完全一致, 可在 `atlas_patch_trainer` 中通过配置开关无缝替换:

```

model_type: cheb_deeponet    # 在 multipatch_training 中
cheb_N: 48

```

`compute_f_derivatives_autograd` 函数通过 `hasattr(model, "forward_with_derivatives")` 自动检测并优先使用精确 Chebyshev 导数, 无需修改训练逻辑。

5 预期性能

5.1 收敛速度

Chebyshev 展开对光滑函数的 L^2 误差满足谱收敛:

$$\|f - \hat{f}_N\|_{L^2} \leq C N^{-k} \|f\|_{H^k}, \quad (12)$$

即对无限可微函数, 误差随 N 指数衰减。 $N = 48$ 对典型 Teukolsky 解应能达到 $\sim 10^{-6}$ 的 y 方向表示精度。

5.2 优化特性

硬边界约束 $f(1) = 1$ 的解析保证使得：

- 初始损失显著降低（无需从随机 $f(1) \neq 1$ 开始优化）。
- 视界附近的 PDE 残差自动降低（函数值和一阶导数的约束部分已满足）。
- 积分一致性损失在 $y = 1$ 处边界项自动为零。

5.3 待验证的假设

1. $N = 48$ 的 Chebyshev 截断对 $\omega \in [10^{-4}, 10]$ 的全频段足够。
2. Taylor 展开结构（4 头）在 Chebyshev 系数空间仍然有效。
3. 无 FiLM 调制时，参数编码器能学习到足够的参数依赖性。
4. L-BFGS 的后优化（利用精确二阶导数）能进一步将精度推到 10^{-4} 以下。

6 参考文献

1. Canuto, C., Hussaini, M. Y., Quarteroni, A., & Zang, T. A. (2006). *Spectral Methods: Fundamentals in Single Domains*. Springer.
2. Lu, L., Jin, P., & Karniadakis, G. E. (2019). DeepONet: Learning nonlinear operators for identifying differential equations based on the universal approximation theorem of operators. *arXiv:1910.03193*.
3. Trefethen, L. N. (2019). *Approximation Theory and Approximation Practice*. SIAM.
4. Teukolsky, S. A. (1973). Perturbations of a rotating black hole. I. Fundamental equations for gravitational, electromagnetic, and neutrino-field perturbations. *ApJ*, 185, 635–647.